Airflow

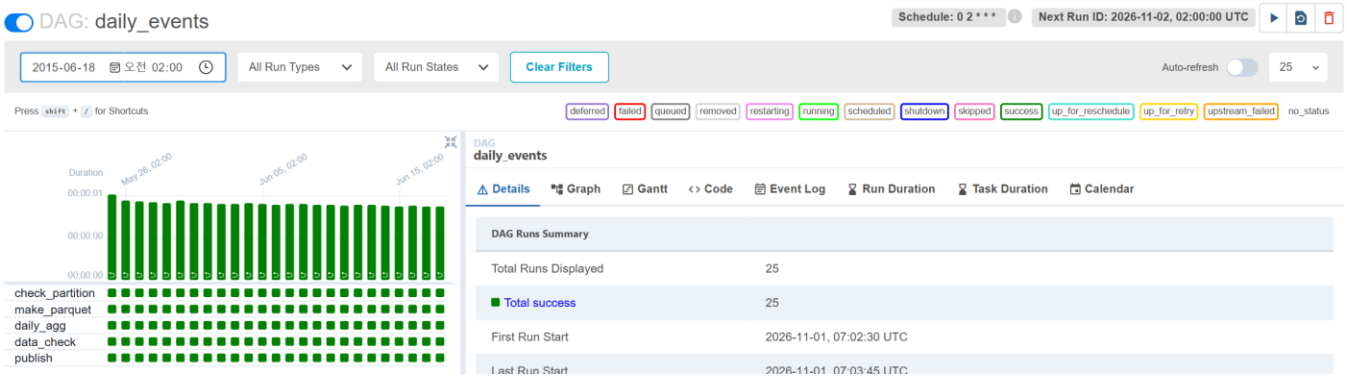
날짜별로 쌓아 둔 Parquet 을 **하루에 한 번** 정리 → 집계 → 검사 → 대시보드 생성.

1. DAG 구조

`check_partition`	→	`make_parquet`	→	`daily_agg`	→	`data_check`	→	`publish`
날짜 확인		파일 합치기 · 중복 제거		하루 상품 집계		품질 검사		대시보드 갱신

어느 Task 든 최종 실패하면 → on_failure_callback(notify_fail) 이 알림

Task	역할	입력 → 출력
`check_partition`	확인할 날짜를 입력으로 주면 해당 폴더가 있는지 날짜의 데이터 모음 폴더가 있는지 검사. 없으면 뒤 Task 전부 skip	`dt=YYYY-MM-DD/` boolean
`make_parquet`	여러 데이터 파일들을 합치고 중복을 제거함	Parquet 8 개 → `combined.parquet` 1 개
`daily_agg`	하루의 상품별 조회 ·· 구매 · 방문자 수를 집계	Parquet → `item_stats_daily`
`data_check`	Null, 중복값, 데이터 개수와 같이 집계에 오류가 없는지 검사	통과 / 실패
`publish`	추후에 만들 대시보드가 읽기 쉽게 하루치 데이터를 요약	Parquet -> `daily_summary`



Grid — 2015-05-03 ~ 06-17 backfill. 화면의 25 회 × 5 Task 전부 초록 (전체 46 일 · 230 Task 모두 success)

멱등성 보장

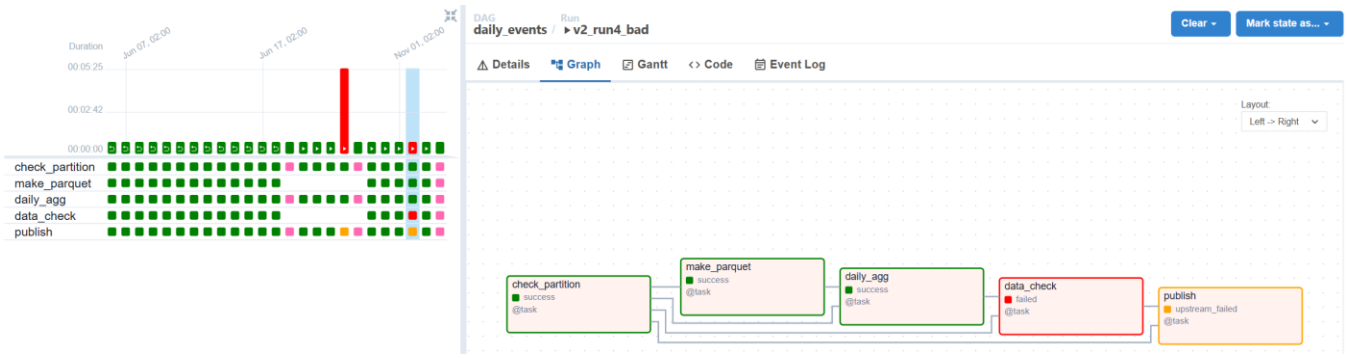
	Parquet	item_stats_daily	daily_summary
1 차 실행	24,020	13,985	24,020
2 차 실행	동일	동일	동일
중복 2,984 건 넣고 실행	동일	동일	동일

2. retry · backoff 전략

기본값 `retries=3` · `retry_delay=1` 분 · `retry_exponential_backoff=True` → 대기 1~2 분 → 2~4 분 → 4~8 분 (실측: 1 분 19 초 → 약 4 분 뒤 재시도, 세 번째에 성공)

구분	Task	이유
재시도	`make_parquet` `daily_agg` `publish`	파일 잠금 · DB 연결 끊김 · 잠깐의 부하 → 기다리면 풀린다. 간격을 늘려 복구 중인 DB 를 계속 두드리지 않는다

바로 알림	`data_check`	데이터가 틀린 건 다시 돌려도 똑같이 틀린다 → `AirflowFailException` 으로 재시도 없이 즉시 실패
재시도 없음	`check_partition`	폴더가 없으면 실패가 아니라 "처리할 것 없음" → skip




```
ALERT :rotating_light: `daily_events.data_check` 실패 (target_date=2015-06-11, try=1)
  – 품질 검사 실패: ['bad_event_type', 'agg_total != row_count'] {'row_count': 20908, 'agg_total': 20907, ...}
```

3. 스케줄 · 의존성

항목	내용
몇 시에	매일 02:00 UTC (`schedule="0 2 * * *"`). 자정
어느 날짜를	실행 전날 하루치 = `data_interval_start` 의 날짜. 예: 11/2 02:00 실행 → 11/1 데이터
실행 날짜 ≠ 데이터 날짜	2015 년 로그 리플레이라 `target_date` 로 직접 지정 (`{"target_date": "2015-06-10"}`) 하거나, backfill 의 logical date 를 2015 년으로
시간대	UTC 로 통일. Spark 가 `dt` 파티션을 UTC 날짜로 만들기 때문
동시 실행 · catchup	`max_active_runs=1` (같은 폴더를 동시에 교체 방지) · `catchup=False` (켜자마자 2015 년부터 수천 번 도는 것 방지)

순서

순서	이유
`check_partition` 이 맨 앞	데이터가 없는 날 뒤 Task 들이 빈 결과를 쓰지 않게 (실제 2026-11-01 스케줄 실행 → 전부 skip)
`make_parquet` → `daily_agg`	중복을 지운 파일로 집계해야 숫자가 맞다
`daily_agg` → `data_check`	원본과 집계를 둘 다 만든 뒤에야 "합계 = 원본 건수" 를 볼 수 있다
`data_check` → `publish`	검사에 실패한 날짜는 대시보드에 올라가지 않는다